

Reconocimiento de Actividades Humanas a partir de Sensores Inerciales de Smartphones

Juan José García Álvarez¹, Valentina Buelvas Martínez¹,
y Tomás Cadavid Martínez¹

¹Universidad de Antioquia, Facultad de Ingeniería, Ingeniería de Sistemas, Medellín, Colombia

Autor de correspondencia: Tomás Cadavid Martínez (e-mail: tomas.cadavid@udea.edu.co)

Este trabajo fue desarrollado con apoyo del curso Fundamentos de Deep Learning del programa de Ingeniería de Sistemas de la Universidad de Antioquia.

ABSTRACT This project addresses the problem of Human Activity Recognition (HAR) using smartphone inertial sensors, a topic relevant to digital health, fitness tracking, and elderly monitoring applications. It is framed as a supervised multiclass classification problem, where accelerometer and gyroscope signals (either raw or represented as a 561-feature vector) are used to predict one of six physical activities: walking, walking upstairs, walking downstairs, sitting, standing, and laying.

The study uses the public UCI HAR Dataset, composed of 10,299 windows of 2.56 seconds collected from 30 volunteers wearing a smartphone at the waist, already partitioned into training (70% of subjects) and test (30%) sets, with a reasonably balanced class distribution. The main reference is the work of Murad & Pyun (2017), which reports 96.7% accuracy using a DRNN architecture, outperforming baselines such as SVM (96.0%), CNN (95.2%), and sequential ELM (93.3%).

Evaluation will combine machine learning metrics (accuracy, precision, recall, macro/weighted F1-score, confusion matrix, and subject-based cross-validation) with business metrics oriented toward realistic deployment (on-device inference latency, energy consumption, false positive rate on risk-relevant classes, and robustness to unseen subjects/devices). The goal is to achieve competitive performance (96–97% accuracy) while assessing the model's ability to generalize to subjects not seen during training.

INDEX TERMS Human Activity Recognition (HAR), Inertial sensors, Smartphones, Accelerometer and gyroscope, Multiclass classification, UCI HAR Dataset, Deep learning, Recurrent Neural Networks, Ubiquitous computing, Digital health.

I. Contexto de la aplicacion

EL reconocimiento de actividad humana (Human Activity Recognition, HAR) a partir de sensores inerciales embebidos en dispositivos móviles es un problema central en *ubiquitous computing*, salud digital y bienestar. A diferencia de los sistemas basados en cámaras, un smartphone portado por el usuario permite monitoreo continuo, de bajo costo y no intrusivo, sin requerir infraestructura externa ni comprometer la privacidad visual del usuario.

Las aplicaciones prácticas de este problema incluyen: (i) aplicaciones de fitness y salud que cuantifican minutos de actividad física diaria; (ii) sistemas de asistencia a adultos mayores que detectan caídas o inactividad prolongada; (iii) interfaces adaptativas que ajustan el comportamiento de una aplicación según el contexto físico del usuario (caminando, sentado, en escaleras); y (iv) telemetría de salud para

poblaciones clínicas (por ejemplo pacientes con Parkinson, donde variantes de este problema se usan para detectar episodios de congelamiento de la marcha). En todos los casos, la propuesta de valor es transformar una señal cruda de acelerómetro/giroscopio —difícil de interpretar directamente— en una etiqueta semántica accionable (caminando, sentado, subiendo escaleras, etc.).

Este proyecto usa como caso de estudio el conjunto de datos público **UCI HAR Dataset** (Human Activity Recognition Using Smartphones), recolectado con un Samsung Galaxy S II portado en la cintura, y se apoya en el artículo de referencia de Murad & Pyun (2017) sobre arquitecturas de redes neuronales recurrentes profundas (DRNN) para esta tarea, el cual reporta resultados de desempeño directamente comparables sobre el mismo dataset.

II. Objetivo de Machine Learning

Se busca predecir la actividad física que realiza una persona (variable categorica de 6 clases) a partir de las señales inerciales de un smartphone (acelerómetro y giroscopio de 3 ejes) capturadas en ventanas de tiempo de 2.56 segundos. Formalmente, es un problema de clasificación multiclase supervisada: dado un vector de entrada x (ya sea la señal cruda de 9 canales $\times$ 128 muestras temporales, o el vector de 561 características de dominio tiempo/frecuencia ya extraídas en el dataset), se busca aprender una función $f(x) \rightarrow y$, donde $y \in \{\text{WALKING, WALKING UPSTAIRS, WALKING DOWNSTAIRS, SITTING, STANDING, LAYING}\}$.

Como extensión natural (etapa posterior del proyecto), se explorará si el modelo puede generalizar a nuevos sujetos no vistos en entrenamiento (validación subject-independent), que es el escenario realista de despliegue en producción.

III. Dataset

A. Origen y tipo de datos

El dataset proviene de 30 voluntarios (19–48 años) que realizaron 6 actividades portando un smartphone en la cintura. El acelerómetro y giroscopio embebidos capturaron aceleración lineal y velocidad angular en 3 ejes a 50 Hz. Las señales se segmentaron en ventanas deslizantes de ancho fijo (128 lecturas, 2.56 s, con 50% de traslape). Para cada ventana se dispone de:

- **Señales inerciales crudas:** 9 canales de series de tiempo (aceleración total y aceleración corporal en X/Y/Z, velocidad angular en X/Y/Z), cada uno de 128 pasos temporales por ventana.
- **Vector de características:** 561 variables numéricas normalizadas en $[-1, 1]$, calculadas en dominio tiempo y frecuencia (media, desviación estándar, entropía, coeficientes FFT, etc.).
- **Etiqueta de actividad** (1 de 6 clases) e **identificador de sujeto** (1–30).

B. Tamaño

El dataset ya viene particionado por los autores originales en 70% de sujetos para entrenamiento y 30% para prueba, lo que evita fuga de información entre sujetos.

TABLA 1. Tamaño del dataset (71.4% train / 28.6% test).

Partición	# Sujetos	# Ventanas (ejemplos)	# Features
Entrenamiento	21	7,352	561
Prueba	9	2,947	561
Total	30	10,299	561

C. Distribucion de clases

TABLA 2. Distribucion de clases por partición. El dataset está razonablemente balanceado (ratio máx/mín ≈ 1.43), por lo que accuracy es una métrica interpretable sin ajustes adicionales, aunque igual se reportará F1 por clase.

Actividad	Train	%	Test	%
WALKING	1,226	16.7%	496	16.8%
WALKING_UPSTAIRS	1,073	14.6%	471	16.0%
WALKING_DOWNSTAIRS	986	13.4%	420	14.3%
SITTING	1,286	17.5%	491	16.7%
STANDING	1,374	18.7%	532	18.1%
LAYING	1,407	19.1%	537	18.2%

IV. Métricas de desempeño

A. Métricas de Machine Learning

- Exactitud global (accuracy): proporción de ventanas correctamente clasificadas; métrica principal dado el balance razonable de clases.
- Precisión y recall por clase, y sus promedios macro: relevantes porque el costo de confundir actividades similares (por ejemplo sitting vs. standing, o subir vs. bajar escaleras) no es simétrico.
- F1-score (macro y ponderado): métrica de resumen robusta ante el leve desbalance de clases.
- Matriz de confusión: para diagnosticar pares de clases sistemáticamente confundidos (se anticipa confusion SITTING/STANDING, dado que ambas son posturas estáticas con perfil inercial similar).
- Validación cruzada por sujeto para estimar la capacidad de generalización a usuarios nuevos, más exigente que la partición aleatoria estándar.

B. Métricas de negocio

- Latencia de inferencia por ventana (ms): crítica si el modelo debe correr en tiempo real dentro del propio dispositivo móvil (on-device inference), condicionando el tamaño y complejidad del modelo elegible.
- Consumo energético/computacional: un modelo más pesado (por ejemplo DRNN de varias capas) puede mejorar accuracy marginalmente a costa de batería, lo cual es relevante para una app de monitoreo continuo.
- Tasa de falsos positivos en clases de riesgo: en aplicaciones de salud (por ejemplo detección de caídas o inactividad prolongada en adultos mayores), minimizar falsos negativos en la clase relevante es más importante que la exactitud global.
- Robustez ante variabilidad de sujeto/dispositivo: qué tanto se degrada el desempeño en usuarios y posiciones de sensor no vistos en entrenamiento, como proxy de qué tan bien generalizaría el modelo en producción real.

V. Referencias y resultados previos

- 1) Anguita, D.; Ghio, A.; Oneto, L.; Parra, X.; Reyes-Ortiz, J. L. (2013). *A Public Domain Dataset for Human Activity Recognition Using Smartphones*. 21st European Symposium on Artificial Neural Networks (ESANN), Bruges, Belgica. — Publicación original del dataset; propone el modelo SVM multiclase usado como línea base de comparacion en (2), con 96.0% de exactitud sobre esta misma tarea.
- 2) Murad, A.; Pyun, J.-Y. (2017). *Deep Recurrent Neural Networks for Human Activity Recognition*. *Sensors*, 17(11), 2556. <https://doi.org/10.3390/s17112556>. — Referencia principal de este proyecto. Propone arquitecturas DRNN (LSTM unidireccional, bidireccional y en cascada) evaluadas en 5 datasets, incluyendo UCI-HAD. Para UCI-HAD, el modelo unidireccional de 4 capas alcanza **96.7% de exactitud global, 96.8% de precisión promedio, 96.7% de recall promedio y F1 = 0.96**, superando a SVM (96.0%), CNN (95.2%) y ELM secuencial (93.3%) reportados por los mismos autores como líneas base de comparación.
- 3) Jiang, W.; Yin, Z. (2015). *Human Activity Recognition using Wearable Sensors by Deep Convolutional Neural Networks*. *Proc. 23rd ACM Int. Conf. on Multimedia*. — Línea base de CNN usada como comparación en (2).
- 4) Chandan Kumar, R.; Bharadwaj, S. S.; Sumukha, B. N.; George, K. (2016). *Human activity recognition in cognitive environments using sequential ELM*. 2nd Int. Conf. on Cognitive Computing and Information Processing. — Línea base de Extreme Learning Machine secuencial.

Resumen de resultados previos sobre este mismo dataset (UCI-HAD):

TABLA 3. Estos valores fijan el umbral de desempeño esperado para el modelo que se desarrollará en este proyecto: superar consistentemente a la línea base de ELM (93.3%) y acercarse o igualar el 96–97% reportado por SVM, CNN y DRNN sobre la misma tarea.

Método (referencia)	Exactitud global
ELM secuencial [4]	93.3%
CNN [3]	95.2%
SVM [1]	96.0%
DRNN unidireccional (4 capas) [2]	96.7%